

Resultados finais: Laplaciano vs. KMeans direto

Trabalho de Teoria Espectral

June 14, 2026

1 Configuração experimental

Foram avaliados três conjuntos de embeddings:

1. **DINOv2 CUB50**: primeiras 50 classes do CUB-200-2011, totalizando 2889 imagens.
2. **DINOv2 Flowers**: Oxford Flowers com 17 classes e 80 imagens por classe.
3. **AlexNet Flowers**: Oxford Flowers usando embeddings extraídos da AlexNet pré-treinada.

Para o método com grafo, usamos a pipeline:

embedding $\rightarrow$ ranking KNN $\rightarrow W \rightarrow L = I - D^{-1/2}WD^{-1/2} \rightarrow$ autovetores $\rightarrow$ KMeans.

O valor usado para o grafo KNN foi:

$$K = 20.$$

Para a ablação, também rodamos KMeans diretamente sobre as matrizes de embeddings, sem construir grafo e sem usar autovetores do Laplaciano.

2 Métricas

Como os índices produzidos pelo KMeans são arbitrários, antes de calcular a acurácia fazemos o melhor pareamento cluster-classe com o algoritmo Húngaro. Nesta tabela, “Acc.” significa essa acurácia após pareamento ótimo.

Experimento	Método	Acc.	ARI	NMI
DINOv2 CUB50	Laplaciano	0.7480	0.6835	0.8842
DINOv2 CUB50	KMeans direto	0.7847	0.7196	0.8803
DINOv2 Flowers	Laplaciano	1.0000	1.0000	1.0000
DINOv2 Flowers	KMeans direto	0.9963	0.9921	0.9930
AlexNet Flowers	Laplaciano	0.6449	0.5262	0.7209
AlexNet Flowers	KMeans direto	0.6404	0.4749	0.6792

3 Leitura dos resultados

No Flowers com DINOv2, os dois métodos são praticamente perfeitos. O Laplaciano atinge 100% nas três métricas, enquanto o KMeans direto fica muito próximo. Isso indica que os embeddings do DINOv2 já separam muito bem as classes desse dataset.

No CUB50 com DINOv2, o KMeans direto obteve acurácia e ARI maiores, enquanto o Laplaciano ficou levemente melhor em NMI. Isso sugere que, para esse subconjunto, o espaço DINOv2

direto já contém uma estrutura de classes forte; o grafo KNN não melhorou a separação medida por acurácia.

No Flowers com AlexNet, o Laplaciano teve pequena vantagem sobre o KMeans direto: a acurácia subiu de 0.6404 para 0.6449, o ARI de 0.4749 para 0.5262 e o NMI de 0.6792 para 0.7209. Aqui o grafo ajudou mais, provavelmente porque os embeddings da AlexNet são menos alinhados com as classes do que os embeddings do DINOv2.

4 Arquivos gerados

Os resultados numéricos da ablação foram salvos em:

- `DataSets/Laplacian/FinalAblation/metrics.csv`
- `DataSets/Laplacian/FinalAblation/metrics.json`

Os arrays do KMeans direto foram salvos em:

- `DataSets/Laplacian/FinalAblation/KMeansOnly/`

Os resultados do Laplaciano com AlexNet foram salvos separadamente em:

- `DataSets/Laplacian/AlexNet/`

5 Figuras do AlexNet




Figure 1: Grafo KNN do AlexNet Flowers colorido pelos clusters espectrais.




Figure 2: Grafo KNN do AlexNet Flowers colorido por acerto/erro após pareamento ótimo.

6 Conclusão

A comparação mostra que o ganho do Laplaciano depende da qualidade e da geometria do embedding inicial. Com DINOv2 em Flowers, as classes já estão quase perfeitamente separadas. Com AlexNet em Flowers, o Laplaciano melhora as métricas em relação ao KMeans direto, indicando que a estrutura de vizinhança do grafo ajuda quando o embedding inicial é menos discriminativo.




Figure 3: Duas primeiras coordenadas do embedding laplaciano para AlexNet Flowers.